Final Report

신용관련 정보 데이터셋을 이용한

신용 점수 Classification과 연체 일수 Regression

1. 문제 정의

금융기관은 고객의 대출 상환 가능성을 정확히 예측하여 신용 리스크를 최소화하고, 동시에 맞춤형 금융 서비스를 제공해야 한다. 그러나 고객의 재무 상황과 상환 이력은 매우 다양하여 기존의 점수 기반 신용평가 방식만으로는 연체 위험을 충분히 반영하기 어렵다. 이에 본 연구에서는 보다 정밀한 신용평가를 위해 **머신러닝 기반 분류 및 회귀 모델**을 활용하고자 한다. 따라서 본 연구는 다음과 같은 두 가지 과제로 구성된다. **Task 1**에서는 개인 금융 데이터를 기반으로 신용 점수를 3단계로 분류하여 연체 위험을 평가하고, **Task 2**에서는 연체 일수를 예측하여 분류 결과를 보완하고 개별 고객의 위험도를 보다 정밀하게 반영한다.

2. 적용한 방법론 설명

2.1 Task 1: Classification

적용 방법론

신용점수(credit_score) 분류를 위해 Random Forest, XGBoost, FT Transformer 총 3가지 모델을 적용하였다. 각 모델에 대해 동일한 데이터 분할 및 전처리 파이프라인을 적용하여 공정한 비교가 가능하도록 하였다. 그리고 다음과 같은 방법들을 적용해 성능 향상을 도모하였다.

첫째, 피처 엔지니어링을 통해 도메인 지식 기반의 파생 변수를 생성하였다. 부채 대비 소득 비율(debt_to_income), 연체 심각도(delay_severity) 등 12개의 비율 및 복합 피처를 추가하여 모델이 신용 위험을 더 효과적으로 학습할 수 있도록 하였다.

둘째, 피처 선택을 통해 Random Forest 기반 피처 중요도를 계산하고 상위 20개 피처만을 선택하여 모델 복잡도를 줄이고 과적합을 방지하였다.

셋째, Optuna 프레임워크를 활용한 베이지안 최적화로 각 모델의 하이퍼파라미터를 효율적으로 탐색하였다. 튜닝 시간 단축을 위해 30% 샘플링 데이터로 최적 파라미터를 찾은 후 전체 데이터로 재학습하였다.

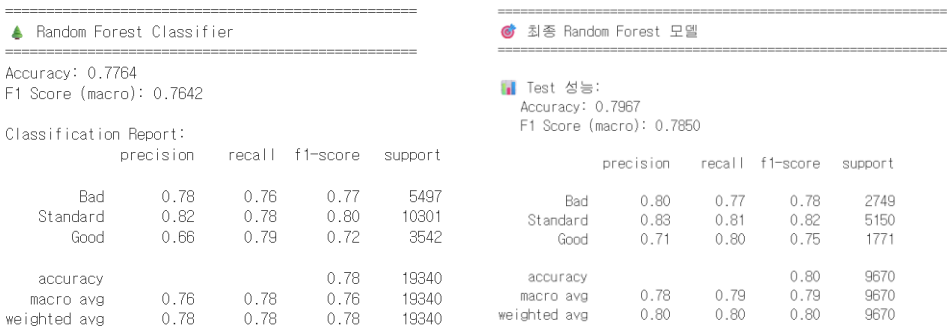
넷째, 과적합 방지를 위해 모델별 정규화 기법을 적용하였다. XGBoost에는 L1/L2 정규화를, FT-Transformer에는 Dropout, Label Smoothing, Early Stopping을 적용하였다.

다섯째, Soft Voting 앙상블을 통해 Random Forest, XGBoost, FT-Transformer의 예측 확률을 가중 평균하여 개별 모델의 약점을 보완하고 최종 성능을 향상시켰다.

모델 실험 결과

2.1.1. Randomforest

하단의 Figure 1.1에서 좌측이 데이터에 단순히 Random Forest 모델을 적용했을 때의 성능, 우측이 성능 극대화 후의 Random Forest 모델의 성능이다.



Random Forest Classifier

Accuracy: 0.7764
F1 Score (macro): 0.7642

Classification Report:

	precision	recall	f1-score	support
Bad	0.78	0.76	0.77	5497
Standard	0.82	0.78	0.80	10301
Good	0.66	0.79	0.72	3542
accuracy			0.78	19340
macro avg	0.76	0.78	0.76	19340
weighted avg	0.78	0.78	0.78	19340

최종 Random Forest 모델

Test 성능:
Accuracy: 0.7967
F1 Score (macro): 0.7850

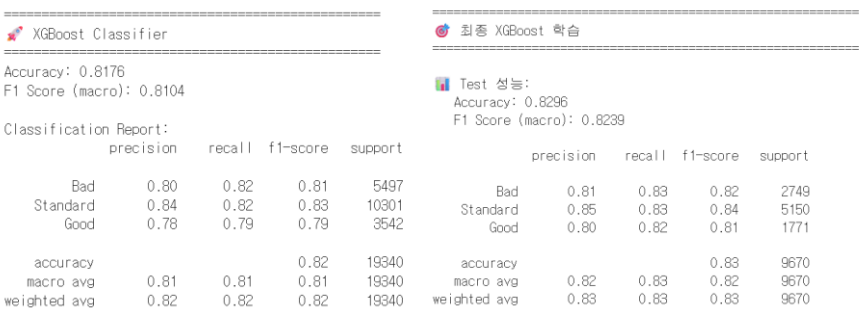
	precision	recall	f1-score	support
Bad	0.80	0.77	0.78	2749
Standard	0.83	0.81	0.82	5150
Good	0.71	0.80	0.75	1771
accuracy			0.80	9670
macro avg	0.78	0.79	0.79	9670
weighted avg	0.80	0.80	0.80	9670

Figure 1.1

본 연구에서는 Random Forest의 성능을 극대화하기 위해 크게 세 가지 접근법을 적용하였다.
첫째, 피처 엔지니어링을 통해 원본 데이터에서 도메인 지식 기반의 파생 변수를 생성하였다. 구체적으로 부채 대비 소득 비율(debt_to_income), EMI 대비 소득 비율(emi_to_income), 연체 심각도(delay_severity) 등 12개의 신규 피처를 추가하였다. 이러한 비율 기반 피처들은 고객의 재무 건전성을 보다 직관적으로 표현함으로써 모델이 신용 위험을 더 정확하게 학습할 수 있도록 하였다.
둘째, Feature Selection을 통해 모델의 복잡도를 줄이고 과적합을 방지하였다. 초기 Random Forest 모델을 학습한 후 피처 중요도(feature importance)를 계산하여 상위 20개의 피처만을 선택하였다. 이를 통해 노이즈가 될 수 있는 저중요도 피처를 제거하고, 모델의 일반화 성능을 향상시켰다.
셋째, Optuna 프레임워크를 활용한 베이지안 최적화 기반 하이퍼파라미터 튜닝을 수행하였다. 탐색 대상 하이퍼파라미터로는 트리 개수(n_estimators), 최대 깊이(max_depth), 분할 최소 샘플 수(min_samples_split), 리프 최소 샘플 수(min_samples_leaf), 그리고 클래스 불균형 처리를 위한 class_weight 등을 설정하였다. 전체 데이터로 튜닝할 경우 시간이 과도하게 소요되어 30% 샘플링된 데이터로 빠르게 최적 파라미터를 탐색한 후, 전체 데이터로 최종 모델을 학습하는 전략을 채택하였다.
최종적으로 Random Forest는 Accuracy 77.64% → 79.67%, F1 Score(macro) 76.42% → 78.50%의 성능 향상을 달성하였다.

2.1.2. XGBoost

하단의 Figure 1.2에서 좌측이 데이터에 단순히 XGBoost모델을 적용했을 때의 성능, 우측이 성능 극대화 후의 XGBoost 모델의 성능이다.



XGBoost Classifier

Accuracy: 0.8176
F1 Score (macro): 0.8104

Classification Report:

	precision	recall	f1-score	support
Bad	0.80	0.82	0.81	5497
Standard	0.84	0.82	0.83	10301
Good	0.78	0.79	0.79	3542
accuracy			0.82	19340
macro avg	0.81	0.81	0.81	19340
weighted avg	0.82	0.82	0.82	19340

최종 XGBoost 학습

Test 성능:
Accuracy: 0.8296
F1 Score (macro): 0.8239

	precision	recall	f1-score	support
Bad	0.81	0.83	0.82	2749
Standard	0.85	0.83	0.84	5150
Good	0.80	0.82	0.81	1771
accuracy			0.83	9670
macro avg	0.82	0.83	0.82	9670
weighted avg	0.83	0.83	0.83	9670

Figure 1.2

본 연구에서는 XGBoost의 성능 향상을 위해 Optuna 기반 하이퍼파라미터 튜닝을 중점적으로

수행하였다. 특히 과적합 방지를 위해 L1 정규화(reg_alpha)와 L2 정규화(reg_lambda) 파라미터를 탐색 범위에 포함시켰으며, 서브샘플링 비율(subsample)과 피처 샘플링 비율(colsample_bytree)을 조절하여 각 트리가 데이터와 피처의 일부만을 학습하도록 하였다. 학습률(learning_rate)은 0.01에서 0.3 사이의 범위에서 탐색하였으며, 트리의 최대 깊이(max_depth)와 리프 노드의 최소 가중치(min_child_weight)도 함께 최적화하였다.

흥미롭게도 XGBoost는 피처 엔지니어링을 적용하지 않은 원본 데이터에서 더 좋은 성능을 보였다. 이는 XGBoost가 자체적으로 피처 간 상호작용을 효과적으로 학습할 수 있기 때문으로 해석된다. 최종적으로 XGBoost는 단일 모델 중 가장 높은 성능인 Accuracy 81.76% → 82.96%, F1 Score(macro) 81.04% → 82.39%를 달성하였다. 이는 Classification Model 가운데 최고 성능이었다.

2.1.3. FT Transformer

본 연구에서는 pytorch-tabular 라이브러리의 의존성 문제로 인해 순수 PyTorch로 FT-Transformer를 직접 구현하였다.

모델 아키텍처는 다음과 같이 구성하였다. 먼저 Feature Tokenizer 단계에서 각 피처 값을 선형 변환을 통해 embed_dim 차원의 임베딩 벡터로 변환한다. BERT와 유사하게 시퀀스 앞에 CLS 토큰을 추가하여 최종 분류에 활용하였으며, Positional Embedding을 통해 피처 간 순서 정보를 반영하였다. Transformer Encoder는 Multi-Head Self-Attention과 Feed-Forward Network로 구성되며, 활성화 함수로는 GELU를 사용하였다.

하단의 Figure 1.3에서 데이터에 단순히 위 FT Transformer모델을 적용했을 때의 성능과 성능 극대화 후의 FT Transformer 모델의 성능을 확인할 수 있다.

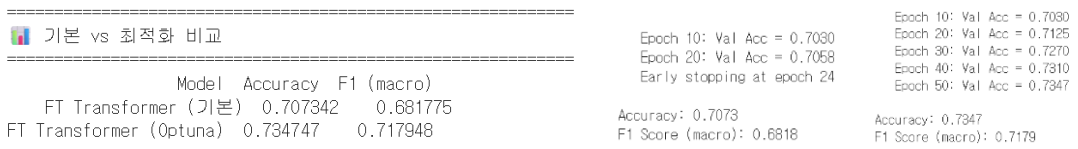


Figure 1.3

성능 향상을 위해 다양한 정규화 및 최적화 기법을 적용하였다. Label Smoothing을 통해 원-핫 인코딩된 타겟 레이블을 부드럽게 만들어 모델의 과신(overconfidence)을 방지하고 일반화 성능을 향상시켰다. 학습률 스케줄링으로는 Cosine Annealing을 적용하여 학습 후반부에 학습률을 점진적으로 감소시켰으며, Gradient Clipping을 통해 그래디언트 폭발을 방지하고 학습 안정성을 확보하였다. AdamW 옵티마이저에 weight decay를 적용하여 L2 정규화 효과를 부여하였고, Early Stopping을 통해 검증 성능이 5 에폭 이상 개선되지 않으면 학습을 조기 종료하도록 하였다.

Optuna를 활용하여 임베딩 차원(embed_dim), 어텐션 헤드 수(num_heads), Transformer 레이어 수(num_layers), 드롭아웃 비율, 학습률, 배치 크기 등을 튜닝하였다. 그러나 FT-Transformer는 Accuracy 70.07 → 73.47%, F1 Score(macro) 68.18 → 71.79%로 트리 기반 모델 대비 낮은 성능을 보였다. 이는 정형 데이터에서 딥러닝 모델이 트리 기반 모델보다 일반적으로 낮은 성능을 보인다는 기존 연구 결과와 일치하며, 특히 데이터 규모가 상대적으로 작고 피처 간 관계가 단순한 경우 Transformer의 복잡한 표현력이 오히려 과적합을 유발할 수 있음을 시사한다.

2.1.4. Ensemble

앙상블 기법은 서로 다른 특성을 가진 여러 모델의 예측을 결합하여 단일 모델보다 더 robust하고 정확한 예측을 수행하는 방법이다. 본 연구에서는 Random Forest, XGBoost, FT-Transformer 세 모델의 예측 확률을 가중 평균하는 Soft Voting 방식을 채택하였다.

Soft Voting은 Hard Voting(다수결 투표)과 달리 각 모델이 출력하는 클래스별 확률값을 활용하므로, 모델의 예측 신뢰도(confidence)를 반영할 수 있다는 장점이 있다. 최종 예측은 가중 평균된 확률값이 가장 높은 클래스로 결정된다.

각 모델은 서로 다른 전처리 파이프라인을 거치므로 앙상블 시 이를 고려하였다. Random Forest는 피처 엔지니어링과 Feature Selection이 적용된 20개 피처를, XGBoost와 FT-Transformer는 원본 피처를 사용하되 FT-Transformer에만 StandardScaler를 적용하였다. 이러한 다양성(diversity)은 앙상블의 성능 향상에 기여하는 요소 중 하나이다.

```
============================================================
🔧 최적 가중치 탐색
============================================================
✅ 최적 가중치: RF=0.3, XGB=0.5, FT=0.2
✅ 최적 F1 Score: 0.8131

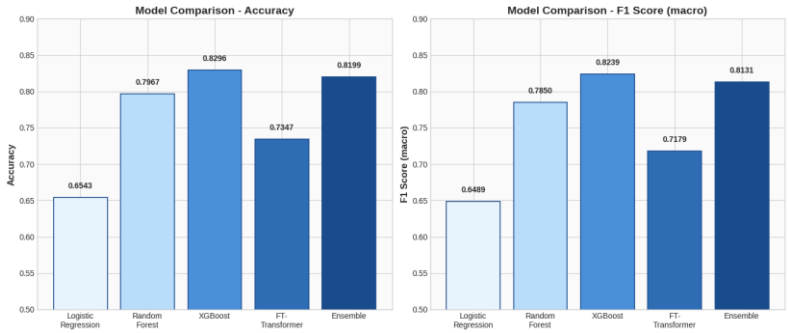
🎯 최적 가중치 앙상블 성능:
   Accuracy: 0.8199
   F1 Score (macro): 0.8131
```

Figure 1.4

최적 가중치를 탐색하기 위해 Grid Search 방식으로 RF, XGBoost, FT-Transformer의 가중치 조합을 0.1 단위로 탐색하였다. 그 결과 RF 0.3, XGBoost 05, FT-Transformer 0.2의 가중치 조합에서 가장 높은 성능을 보였으며, 최종적으로 Accuracy 81.99%, F1 Score(macro) 81.31%를 달성하여 모든 단일 모델을 상회하는 성능을 기록하였다. 이는 서로 다른 학습 방식과 귀납적 편향(inductive bias)을 가진 모델들을 결합함으로써 개별 모델의 약점을 보완하고 예측의 분산을 줄일 수 있음을 보여준다.

종합 비교 및 분석

XGBoost가 Accuracy 82.96%, F1 Score 82.39%로 가장 높은 성능을 달성하였으며, Ensemble 모델이 그 뒤를 각각 81.99%, 81.31%로 따른다.



첫째, 단일 모델 중 XGBoost가 가장 높은 성능(Accuracy 82.96%)을 달성하였으며, 이는 Boosting의 순차적 오차 보정과 정규화 기법이 정형 데이터의 비선형 패턴 학습에 효과적임을 보여준다.

둘째, FT-Transformer가 트리 기반 모델 대비 약 8~10%p 낮은 성능을 기록한 것은 정형 데이터의 특성에 기인한다. Transformer는 인접 요소 간 강한 상관관계가 있는 이미지나 텍스트에 적합하며,

피처 간 순서가 무의미하고 분포가 이질적인 정형 데이터에서는 트리 모델의 분기(split) 기반 학습이 더 효과적임을 알 수 있다.

셋째, 피처 엔지니어링 효과가 모델마다 상이하게 나타났다. Random Forest는 파생 변수 추가로 약 2%p 향상을 보였으나, XGBoost는 원본 데이터에서 더 좋은 성능을 기록하여 자체적인 피처 상호작용 학습 능력이 뛰어남을 확인하였다.

넷째, Ensemble(81.99%)이 XGBoost 단일 모델(82.96%)보다 낮은 성능을 보인 것은 FT-Transformer의 낮은 성능이 전체를 끌어내린 결과이다. 이는 Soft Voting 앙상블에서 참여 모델 간 성능 균형이 중요하며, 성능 격차가 큰 모델 포함 시 오히려 역효과가 발생할 수 있음을 시사한다.

2.2 Task 2: Regression

적용 방법론

연체 일수(delay_from_due_date) 예측을 위해 Linear Regression, Random Forest, XGBoost, FT Transformer 총 4가지 모델을 적용하였다. 각 모델에 대해 동일한 데이터 분할 및 전처리 파이프라인을 적용하여 공정한 비교가 가능하도록 하였다. 데이터는 Train(77,366건, 80%), Validation(9,660건, 10%), Test(9,670건, 10%)로 분할하였으며, 총 96,696건의 샘플과 45개의 피처를 사용하였다. 수치형 변수에는 StandardScaler를 적용하여 평균 0, 표준편차 1로 정규화하였고, 범주형 변수는 One-Hot Encoding을 통해 수치형으로 변환하였다.

모델 성능 향상을 위해 기존 45개 피처로부터 14개의 파생 피처를 추가 생성하였다. 생성된 피처는 크게 네 가지 유형으로 구분된다. 첫째, 비율 피처로 debt_to_income(부채/월소득), emi_to_income(월할부금/월소득), invest_to_income(월투자금/월소득), loan_per_card(대출수/신용카드수)를 생성하여 재무 건전성을 상대적 비율로 표현하였다. 둘째, 상호작용 피처로서 delay_interest_interaction(연체횟수×이자율), util_debt_interaction(신용이용률×부채), age_history_interaction(나이×신용기록기간)을 생성하여 변수 간 복합적 관계를 반영하였다. 셋째, 집계 피처로서 total_accounts(총계좌수), financial_burden(금융부담점수)을 생성하였다. 넷째, 변환 피처로서 delayed_payment_sq, credit_util_sq(제곱 변환)와 log_annual_income, log_outstanding_debt(로그 변환)를 생성하여 비선형 패턴과 분포 왜도를 보정하였다.

피처 선택을 위해 XGBoost Regressor를 활용하여 각 피처의 중요도를 산출하였다. XGBoost 기반 중요도는 트리 분할 과정에서 각 피처의 기여도를 측정하므로, 피처 간 비선형 관계와 상호작용을 고려한 선택이 가능하다. 이는 Linear Regression부터 FT Transformer까지 다양한 모델에 범용적으로 적용할 수 있다는 장점이 있다. 추가로 피처 간 상관계수가 0.95 이상인 쌍을 탐색하여, 중복 정보를 제공하는 피처 중 중요도가 낮은 쪽을 제거하였다. 최종적으로 중요도 상위 40개 피처를 선택하여 모델 학습에 활용하였다.

각 모델의 하이퍼파라미터 최적화를 위해 Optuna 라이브러리의 TPE(Tree-structured Parzen Estimator) 샘플러를 활용하였다.Validation R^2를 최대화하는 방향으로 50~100회의 trial을 수행하여 최적 파라미터를 탐색하였다. 베이지안 최적화 기반의 TPE는 이전 trial 결과를 활용하여 유망한

파라미터 영역을 집중 탐색하므로, Grid Search나 Random Search 대비 효율적인 탐색이 가능하다.

모델별 실험 결과

2.2.1 Linear Regression

Linear Regression은 해석력이 높고 계산 효율이 우수하여 baseline 모델로 활용하였다.

그러나 변수 간 비선형 관계를 포착하지 못하는 본질적 한계가 존재한다.

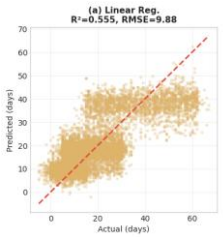
Baseline 모델의 Test R^2는 0.5161로, 연체 일수 변동의 약 절반만 설명할 수 있었다. Ridge, Lasso, ElasticNet 등 정규화 기법과 피처 엔지니어링을 적용하였으나 유의미한 개선이 없었다. 반면 2차 다항 피처(Polynomial Features)와 Ridge를 결합한 모델은 Test R^2 = 0.5546을 달성하여 Baseline 대비 7.5%의 성능 향상을 보였다. 이는 다항 피처를 통해 변수 간 상호작용을 일부 포착한 결과로 해석된다.

예측값과 실제값의 산점도 분석 결과, 연체 일수 30~50일 구간에서 예측값이 실제값을 체계적으로 과소추정하는 패턴이 관찰되었다. 이는 선형 모델의 한계를 명확히 보여주며, 비선형 모델의 필요성을 시사한다.

📊 Linear Regression 개선 결과 요약

	val_r2	test_r2	test_mae	test_rmse
Baseline	0.5167	0.5161	8.1762	10.3038
Feature Engineering	0.5179	0.5160	8.1766	10.3045
Feature Selection	0.5146	0.5139	8.2039	10.3264
Ridge (Optuna)	0.5146	0.5140	8.2041	10.3262
Lasso (Optuna)	0.5148	0.5144	8.1991	10.3216
ElasticNet (Optuna)	0.5148	0.5144	8.1994	10.3216
Poly + Ridge (Optuna)	0.5579	0.5546	7.8837	9.8849

🏆 Best Linear Model: Poly + Ridge (Optuna) (Test R^2 = 0.5546)



2.2.2. Random Forest

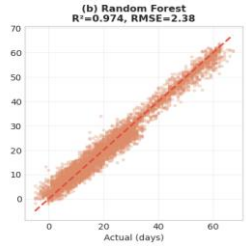
Baseline 모델(n_estimators=100, max_depth=15)의 Test R^2는 0.8282로, Linear Regression 대비 약 60% 높은 설명력을 보였다. 흥미롭게도 Feature Engineering(R^2=0.8235)과 Feature Selection(R^2=0.8157) 적용 시 오히려 성능이 소폭 하락하였다. 이는 Random Forest가 자체적으로 피처 간 상호작용을 학습하고 중요도가 낮은 피처의 영향을 자동으로 감소시키는 특성 때문으로 해석된다.

Optuna를 활용한 하이퍼파라미터 튜닝(100 trials) 결과, Test R^2 = 0.9742, MAE = 1.6755, RMSE = 2.3777을 달성하였다. 이는 Baseline 대비 R^2기준 17.6%p 향상, MAE 기준 66% 오차 감소에 해당한다. Validation R^2(0.9729)와 Test R^2(0.9742)가 거의 동일하여 과적합 없이 일반화 성능이 확보되었음을 확인하였다.

📊 Random Forest 개선 결과 요약

	val_r2	test_r2	test_mae	test_rmse
Baseline	0.8247	0.8282	4.9293	6.1388
Feature Engineering	0.8215	0.8235	4.9913	6.2220
Feature Selection	0.8133	0.8157	5.0861	6.3593
Optuna Tuning	0.9729	0.9742	1.6755	2.3777

🏆 Best RF Stage: Optuna Tuning (Test R^2 = 0.9742)



2.2.3. XGBoost

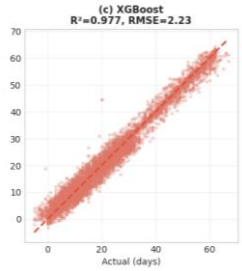
Baseline 모델(n_estimators=100, max_depth=6, learning_rate=0.1)의 Test R^2는 0.6838로, Random

Forest Baseline(0.8282)보다 낮은 성능을 보였다. 이는 XGBoost의 기본 하이퍼파라미터가 해당 데이터셋에 최적화되지 않았기 때문으로 판단된다. Feature Engineering 적용 시 R^2=0.6906으로 소폭 개선되었으나, Feature Selection 적용 시 R^2=0.6855로 다시 하락하였다.

Optuna 튜닝(100 trials) 결과, Test R^2 = 0.9773, MAE = 1.5212, RMSE = 2.2333을 달성하여 전체 모델 중 가장 우수한 성능을 기록하였다. Baseline 대비 총 42.91%의 R^2 개선율을 보였다. 최적화된 주요 하이퍼파라미터로는 n_estimators, max_depth, learning_rate, subsample, colsample_bytree, reg_alpha, reg_lambda 등이 있으며, 특히 정규화 파라미터의 적절한 설정이 성능 향상에 크게 기여한 것으로 분석된다.

```
======================================================================
▌XGBoost 개선 과정 요약
======================================================================
                    단계   Val R²  Test R²  Test MAE  Test RMSE
          0. Baseline 0.676642 0.683823  6.764810   8.328553
. Feature Engineering 0.689165 0.690631  6.701345   8.238393
 2. Feature Selection 0.684511 0.685510  6.755561   8.306299
     3. Optuna Tuning 0.976943 0.977266  1.521238   2.233276

✓ 총 R² 개선율: 42.91%
  Baseline: 0.6838 → Final: 0.9773
```



2.2.4. FT Transformer.

모델 구조는 Numerical Embedding 레이어를 통해 수치형 피처를 d_model 차원으로 임베딩한 후, CLS 토큰과 결합하여 Transformer Encoder에 입력하는 방식으로 구성하였다. 학습에는 AdamW 옵티마이저와 ReduceLROnPlateau 스케줄러를 사용하였으며, Early Stopping(patience=15)을 적용하여 과적합을 방지하였다. Baseline 모델에서는 d_model=64, n_heads=4, n_layers=2, d_ffn=128, dropout=0.1의 하이퍼파라미터를 설정하였다.

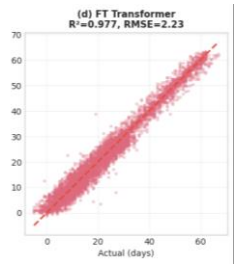
Baseline FT Transformer의 Test R^2는 0.8618로, Linear Regression(0.5546)보다 크게 높고 Random Forest Baseline(0.8282)보다도 우수한 성능을 보였다. 이는 FT Transformer가 별도의 튜닝 없이도 피처 간 복잡한 관계를 효과적으로 학습할 수 있음을 시사한다. 그러나 Feature Engineering 적용 시 R^2=0.8345, Feature Selection 적용 시 R^2=0.7943으로 오히려 성능이 하락하였다. 이는 Transformer 모델이 원본 피처로부터 자체적으로 유의미한 표현(representation)을 학습하는 특성 때문으로, 수동으로 생성한 파생 피처가 오히려 학습을 방해한 것으로 해석된다.

Optuna를 활용한 하이퍼파라미터 튜닝(50 trials)을 통해 d_model, n_heads, n_layers, d_ffn, dropout, learning_rate, batch_size를 최적화하였다. 최적화된 FT Transformer 모델은 Validation R^2 = 0.9729, Test R^2 = 0.9752, MAE = 1.6796, RMSE = 2.3320을 달성하였다. 이는 Baseline 대비 R^2 기준 13.17%의 개선에 해당하며, XGBoost(R^2=0.9773)와 거의 동등한 수준의 성능을 보여주었다.

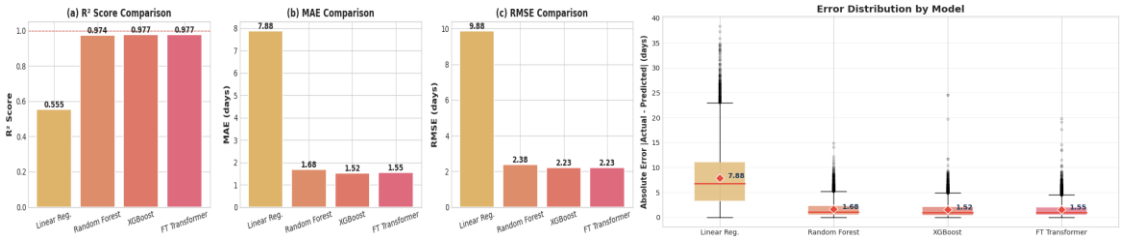
학습 과정에서 Validation Loss가 Epoch 10의 74.86에서 Epoch 100의 24.01까지 꾸준히 감소하는 양상을 보였으며, 이는 모델이 안정적으로 수렴하였음을 나타낸다. 예측값과 실제값의 산점도 분석 결과, 연체 일수 전 범위에서 Perfect Prediction 선에 근접한 분포를 보여 트리 기반 모델과 유사한 수준의 예측 정확도를 확인하였다.

```
======================================================================
📊 FT Transformer 개선 과정 요약
======================================================================
                  단계   Val R²  Test R²  Test MAE  Test RMSE
          0. Baseline 0.866627 0.861754  4.305250   5.507200
1. Feature Engineering 0.834931 0.834490  4.789339   6.025813
  2. Feature Selection 0.793046 0.794281  5.358483   6.718019
      3. Optuna Tuning 0.972945 0.975212  1.679646   2.331974

🚀 총 R² 개선율: 13.17%
   Baseline: 0.8618 → Final: 0.9752
```



종합 비교 및 분석



최종 성능 기준으로 XGBoost가 Test R^2 = 0.9773으로 가장 우수하였으며, FT Transformer(0.9752)와 Random Forest(0.9742)가 근소한 차이로 뒤를 이었다. 세 모델 모두 MAE 약 1.6일, RMSE 약 2.3일 수준의 매우 낮은 오차를 달성하였다.

첫째, 비선형 모델의 압도적 우수성이 확인되었다. Linear Regression의 최고 성능(R^2=0.5546)과 비선형 모델들의 성능(R^2>0.97) 사이의 큰 격차는 연체 일수 예측 문제가 본질적으로 비선형적 특성을 가짐을 명확히 보여준다. 고객의 연체 행동은 단일 변수의 선형적 영향이 아닌, 여러 금융 지표의 복합적 상호작용에 의해 결정됨을 시사한다.

둘째, 하이퍼파라미터 튜닝이 모델 성능 향상의 핵심 요인임을 확인하였다. 특히 XGBoost는 Baseline(R^2=0.6838)에서 Optuna 튜닝 후(R^2=0.9773)로 42.9%의 개선을 보여, 동일 알고리즘이라도 파라미터 최적화에 따라 성능이 극대화될 수 있음을 보여준다. 반면 수동 Feature Engineering과 Feature Selection은 트리 기반 및 Transformer 모델에서 오히려 성능 저하를 유발하는 경우가 많았다. 이는 해당 모델들이 자체적으로 피처 간 상호작용과 중요도를 학습하는 능력을 갖추고 있기 때문으로 해석된다.

셋째, 딥러닝 모델(FT Transformer)이 tabular 데이터에서도 트리 기반 앙상블 모델과 대등한 성능을 달성할 수 있음을 확인하였다. 전통적으로 tabular 데이터에서는 XGBoost, LightGBM 등 트리 기반 모델이 우세하다고 알려져 있으나, 적절한 튜닝을 거친 FT Transformer는 XGBoost와 0.21%p 차이의 거의 동등한 성능을 보였다.

넷째, 모든 최종 모델에서 Validation과 Test 성능이 거의 동일하여(Random Forest: 0.9729 vs 0.9742, XGBoost: 0.9769 vs 0.9773, FT Transformer: 0.9729 vs 0.9752) 과적합 없이 안정적인 일반화 성능이 확보되었음을 확인하였다.

3. 최종 결과 및 해석

금융기관은 고객의 대출 상환 가능성을 정확히 예측함으로써 신용 리스크를 최소화하고, 동시에 고객에게 맞춤형 금융 서비스를 제공해야 하는 중요한 과제를 안고 있다. 그러나 각 고객의 재무 상황, 소득 구조, 지출 습관, 과거 상환 이력 등은 매우 다양하며, 단순히 신용등급이나 제한된 재무 지표만으로는 연체 위험을 충분히 평가하기 어렵다. 이러한 복잡한 환경에서는 전통적인 점수 기반 신용평가 방식만으로는 한계가 존재하며, 보다 정밀하고 데이터 기반의 분석이 요구된다. 이에 본 연구에서는 금융기관이 합리적으로 대출 승인 여부와 한도를 결정할 수 있도록, 머신러닝 기반의 분류(Classification) 모델을 개발하고자 한다. 분류 모델은 개인 고객을 연체 가능성 또는 신용 점수 수준에 따라 체계적으로 구분함으로써, 리스크 관리와 대출 심사 프로세스의 효율성을 동시에 개선할 수 있다. 아울러 연체 일수와 같은 연속적 위험 지표를 예측하는 회귀(Regression) 모델을 추가로 적용함으로써, 단순한 등급 분류를 넘어 보다 세밀한 신용평가 체계를 구축할 수 있다. 본 연구는 크게 두 단계(Task)로 구성된다. Task1에서는 개인 고객의 금융 데이터를 기반으로 신용 점수를 세 단계로 분류하여 고객의 연체 위험을 정량적으로 평가한다. Task2에서는 고객의 연체 일수를 예측하여, 분류 모델에서 제공하는 범주형 평가를 보완하고, 개별 고객의 상환 패턴과 위험도를 보다 정밀하게 반영하는 신용평가 체계를 구축한다.

4. 결과 기반 연구/개발 가능성 논의

4.1 FT-Transformer 기반 정형 데이터 딥러닝

Task 1에서는 FT-Transformer가 트리 모델 대비 낮은 성능을 보였으나, Task 2에서는 XGBoost와 거의 동등한 성능(R^2 =0.9752)을 달성하였다. 이는 FT-Transformer가 적절한 하이퍼파라미터 튜닝과 데이터 규모가 확보될 경우, 정형 데이터에서도 충분히 경쟁력 있는 모델이 될 수 있음을 의미한다. 향후 연구에서 범주형 변수를 포함한 임베딩 구조 확장, Multi-task Learning을 통한 분류·회귀 동시 학습, 대규모 금융 데이터셋을 활용한 사전학습(Pre Training) 등으로 확장하여 Transformer 기반 신용 평가 모델의 일반화 성능과 안정성을 더욱 강화할 수 있을 것이다.

4.2 피처 엔지니어링 및 모델 선택 전략

앞선 결과에서 Random Forest에서는 피쳐 엔지니어링이 성능 향상에 기여한 반면, XGBoost와 FT-Transformer에서는 오히려 원본 피처가 더 좋은 성능을 보였다. 이는 향후 연구에서 모델 중심(feature-free) 접근과 도메인 지식 기반 피처 설계 접근을 병행하는 전략적 모델 선택의 중요성을 시사한다.